

Taiwanese Bankruptcy Prediction

Projekat na kursu Istraživanje podataka 2

1. Uvod i opis zadatka

U savremenom finansijskom svetu, sposobnost ranog identifikovanja kompanija u riziku od bankrota predstavlja jednu od ključnih kompetencija modernog ekonomskog sistema. Investitori, regulatori, kreditne institucije i sami menadžeri kompanija imaju direktan interes u što tačnijem predviđanju finansijskog kolapsa, kako bi mogli pravovremeno da reaguju, restrukturiraju dugove ili povuku kapital pre nego što nastupi nepopravljiva šteta.

Cilj ovog istraživanja je višeslojna analiza skupa podataka "Taiwanese Bankruptcy Prediction" i razvoj modela mašinskog učenja koji mogu sa visokom pouzdanošću klasifikovati poslovne subjekte. Posebna pažnja posvećena je izazovu koji predstavlja realan, nebalansirani karakter finansijskih podataka, gde je slučajeva bankrota drastično manje nego slučajeva stabilnog poslovanja, što algoritmima mašinskog učenja otežava da ovu manjinsku klasu uopšte nauče da prepoznaju.

Problem je formalizovan kao zadatak binarne klasifikacije: na osnovu istorijskih finansijskih pokazatelja, model mora da predvidi jedno od dva stanja: stabilno poslovanje (klasa 0) ili bankrot (klasa 1). Ono što ovaj zadatak čini posebno izazovnim nije sama predikcija, već optimizacija modela za detekciju kritične klase u uslovima gde greška tipa II (propušteni bankrot) nosi neuporedivo veće poslovne posledice od greške tipa I (lažna uzbuna).

Ovaj rad se ne fokusira isključivo na postizanje visoke ukupne tačnosti (accuracy), već uvodi **odziv (recall)** kao primarnu metriku uspeha, što u kontekstu finansijskog rizika predstavlja daleko relevantniji pokazatelj kvaliteta modela.

2. Opis podataka

Podaci korišćeni u ovom radu potiču iz UCI Machine Learning repozitorijuma, a inicijalno su prikupljeni u skladu sa ekonomskim regulativama Tajvanske berze za vremenski period od 1999. do 2009. godine. Ovaj period obuhvata kako relativno stabilne tržišne uslove s kraja devedesetih, tako i turbulencije koje su pratile dot-com balon i početke globalne finansijske krize, što skup podataka čini posebno bogatim i relevantnim.

Broj instanci: 6.819 kompanija.

Broj atributa: 95 nezavisnih varijabli koje obuhvataju različite aspekte poslovanja: likvidnost, profitabilnost, zaduženost i operativnu efikasnost.

Ciljna promenljiva: Bankrupt? (1 = Bankrot, 0 = Nije bankrot)

Distribucija klasa predstavlja jedan od centralnih izazova ovog skupa podataka. Manje od 4% kompanija je zapravo bankrotiralo, dok preostalih 96%+ čine finansijski stabilni subjekti.

Ovakav disbalans je u potpunosti u skladu sa realnim ekonomskim kretanjima. Bankrot je statistički redak događaj, što ga čini teškim za predviđanje algoritmima koji teže da minimizuju ukupnu grešku.

Svaki od 95 atributa predstavlja jedan finansijski koeficijent koji se standardno koristi u računovodstvenim i finansijskim analizama. Ovi pokazatelji pokrivaju dimenzije kao što su racio tekuće likvidnosti, obrt sredstava, stopa zaduženosti, marža neto profita, prinos na imovinu (ROA), prinos na kapital (ROE), i mnogi drugi. Ključni izazov leži u tome što mnogi od ovih atributa mogu biti visoko korelisani međusobno, što unosi statistički šum i potencijalno narušava stabilnost modela.

Vizualizacija kroz PCA redukciju na dva glavna komponenta otkrila je značajno prostorno preklapanje između dve klase, što direktno sugerise da granica odlučivanja nije linearna, a da su obrasci bankrota suptilni i netrivialni za detekciju. Ova observacija je opredelila dalji metodološki pristup u pravcu nelinearnih algoritama i pažljive selekcije atributa.

3. Metodologija i obrada podataka

3.1. Čišćenje podataka i vizualizacija

Prva faza preprocesiranja obuhvatila je sistematsku proveru kvaliteta podataka. Potvrđeno je da skup podataka ne sadrži nedostajuće vrednosti ni u jednom od 95 atributa za svih 6.819 instanci, što je izuzetno pozitivna karakteristika koja značajno pojednostavljuje preprocesiranje i ukazuje na visok nivo urednosti originalnih finansijskih zapisa.

U cilju vizualizacije i intuitivnog razumevanja strukture podataka, primenjena je PCA (Principal Component Analysis) metoda za redukciju dimenzionalnosti na dva glavna faktora. Dobijeni dijagram rasipanja jasno je pokazao da klase nisu linearno separabilne, instance bankrota i stabilnih kompanija se u velikoj meri prostorno preklapaju. Ova observacija je imala direktan uticaj na izbor algoritama: favorizovani su modeli koji mogu da nauče kompleksne, nelinearne granice odlučivanja.

3.2. Skaliranje atributa

Finansijski koeficijenti u skupu podataka izraženi su u veoma različitim skalama i rasponima vrednosti. Racio likvidnosti može imati vrednosti bliske 1, dok vrednosti prihoda izražene u apsolutnim ciframa mogu biti višestruko veće. Ovakva razlika u skalama može ozbiljno narušiti performanse algoritama koji su osetljivi na magnitude atributa.

Iz tog razloga, na svim atributima primenjen je **StandardScaler**, koji svaki atribut transformiše na nultu srednju vrednost i standardnu devijaciju jedan. Ova transformacija je posebno kritična za algoritme poput SVM-a i KNN-a, gde udaljenosti ili optimizacioni kriterijumi direktno zavise od apsolutnih vrednosti atributa.

3.3. Rešavanje problema nebalansiranosti — SMOTE

Nebalansiranost klasa predstavlja možda i najveći tehnički izazov ovog projekta. Model koji bi naivno klasifikovao svaku kompaniju kao stabilnu (klasa 0) postigao bi tačnost od ~96%, a da pritom ne detektuje ni jedan jedini bankrot. Ovo je klasična zamka kojoj podlegu mnogi algoritmi koji optimizuju ukupnu tačnost.

Kako bi se ovaj problem prevazišao, na trening skupu je primenjena tehnika **SMOTE (Synthetic Minority Over-sampling Technique)**. Za razliku od jednostavnog dupliranja postojećih primera manjinske klase (random oversampling), SMOTE generiše **sintetičke** primere koristeći interpolaciju između k-najbližih suseda u prostoru obeležja. Na taj način, model dobija na uvid ne samo originalne primere bankrota, već i ceo spektar interpolovanih primera koji popunjavaju prazan prostor oko klase bankrota, omogućavajući algoritmu da nauči obrasce koji prethode finansijskom kolapsu.

Važno je napomenuti da je SMOTE primenjen isključivo na trening skupu, nakon podele podataka na trening i test skup. Primena SMOTE na celokupnom skupu podataka pre podele bila bi oblik curenja podataka koji bi veštački poboljšao rezultate na testiranju.

3.4. Selekcija atributa — SelectKBest

U cilju provere da li se može postići jednaka ili bolja prediktivna moć uz manji broj atributa, primenjena je statistička selekcija obeležja. Korišćenjem metode SelectKBest sa ANOVA F-testom, izmeren je stepen zavisnosti između svakog atributa i ciljne promenljive, a zatim je izabrano 10 atributa sa najvišim F-skorovima.

Ova redukcija sa 95 na 10 atributa ima dvostruku svrhu: s jedne strane, smanjuje rizik od preprilagođavanja eliminišući attribute koji su noisy ili redundantni; s druge strane, povećava interpretabilnost modela, što je od kritičnog praktičnog značaja za kreditne analitičare i menadžere koji moraju da razumeju zašto model donosi određenu odluku.

Deset najznačajnijih atributa koji su selektovani dominiraju indikatori profitabilnosti i zaduženosti: pre svega ROA (Return on Assets - neto prihod prema ukupnoj imovini) i Debt Ratio (ukupne obaveze prema ukupnoj imovini). Ovo je u potpunosti u skladu sa tradicionalnom finansijskom teorijom, koja ove dve dimenzije smatra primarnim signalima finansijskog zdravlja kompanije.

4. Korišćeni algoritmi

Odabir algoritama mašinskog učenja pažljivo je osmišljen kako bi pokrio različite paradigme klasifikacije, od jednostavnih linearnih modela do kompleksnih ansambala, i kako bi pružio uvid u širok spektar pristupa rešavanju ovog problema.

4.1. Logistic Regression

Logistička regresija služi kao osnovni model i standard za poređenje. Uprkos svojoj relativnoj jednostavnosti, logistička regresija ima nekoliko važnih prednosti: interpretabilnost koeficijenata, robustnost na manje skupove podataka i dobru kalibraciju verovatnoća. U kontekstu predikcije bankrota, koeficijenti modela direktno govore koji finansijski indikatori i u kojoj meri doprinose verovatnoći kolapsa. Na redukovanom skupu atributa, ovaj model je postigao izuzetan odziv od 0.85, što ga čini iznenađujuće kompetitivnim uprkos pretpostavkama.

4.2. Decision Tree

Stabla odlučivanja pružaju uvid u logiku klasifikacije kroz hijerarhiju pravila zasnovanih na pragu vrednosti pojedinih atributa. Prednost ovog pristupa leži u lakoći interpretacije, moguće je tačno pratiti putanju kroz stablo i razumeti zašto je kompanija klasifikovana kao rizična. Međutim, stabla odlučivanja su sklona preprilagođavanju, posebno kada se dozvoli rast do

maksimalne dubine. U ovom projektu, Decision Tree je postigao solidnu tačnost od 93.94% na punom skupu atributa, ali uz značajno niži odziv u poređenju sa jednostavnijim modelima.

4.3. Random Forest

Random Forest je ansambl metoda koja kombinuje veliki broj stabala odlučivanja, pri čemu svako stablo trenira na nasumičnom poduzorku podataka i nasumičnom podskupu atributa. Ovaj pristup drastično smanjuje varijansu modela i rizik od preprilagođavanja. Sa tačnošću od 96.24% na punom skupu atributa, Random Forest je dominirao po ovoj metrici. Međutim, njegova visoka ukupna tačnost ne prati se visokim odzivom za klasu bankrota (0.55), što jasno ilustruje zašto tačnost nije dovoljna metrika za nebalansirane skupove podataka.

4.4. K-Nearest Neighbors (KNN)

KNN je algoritam koji klasifikuje novu instancu na osnovu klase njenih k najbližih suseda u prostoru obeležja. Intuicija je ekonomski elegantna: kompanije sa sličnim finansijskim profilom verovatno dele sličnu sudbinu. KNN ne gradi eksplicitan model, umesto toga, čuva sve trening primere u memoriji i svrstava novu kompaniju u klasu koja dominira u njenoj okolini. Ovaj algoritam je posebno osetljiv na skaliranje atributa i dimenzionalnost prostora, zbog čega su StandardScaler i redukcija atributa imali direktan pozitivan uticaj na njegove performanse.


4.5. Support Vector Machine (SVM)

SVM pokušava da pronađe optimalnu hiperravan koja maksimizuje marginu između dve klase. U slučajevima gde klase nisu linearno separabilne, SVM koristi kernel trik, transformaciju podataka u višedimenzionalni prostor u kom separacija može postati moguća. Na redukovanom skupu atributa, SVM je pokazao visok odziv, mada uz nisku preciznost, što ga čini prikladnim za scenarije gde je prioritet minimizacija propuštenih bankrota.

5. Evaluacija - metrike i vizuelizacije


5.1. Metrike evaluacije

Svaki model je evaluiran kroz više metrika kako bi se dobila potpuna slika njegovih performansi. Pored ukupne tačnosti, mereni su odziv, preciznost i F1-skor posebno za klasu bankrota (klasa 1). Za svaki model generiše se matrica konfuzije koja jasno prikazuje raspodelu tačno pozitivnih, lažno pozitivnih, tačno negativnih i lažno negativnih predikcija.




5.2. ROC krive i AUC

ROC (Receiver Operating Characteristic) krive vizuelizuju trade-off između stope tačno pozitivnih (TPR) i stope lažno pozitivnih (FPR) pri različitim pragovima klasifikacije. Površina ispod krive (AUC) služi kao skalarna mera ukupne diskriminacijske sposobnosti modela, nezavisna od konkretnog praga odlučivanja. Grafik prikazuje ROC krive za oba scenarija (svi atributi i redukovani skup) na odvojenim panelima, što omogućava direktno poređenje.



5.3. Precision-Recall krive

Za nebalansirane skupove podataka, Precision-Recall kriva je informativnija od ROC krive. Ona direktno vizuelizuje tension između preciznosti i odziva pri različitim pragovima, bez uticaja dominantne negativne klase. Average Precision (AP) skor sumira površinu ispod PR krive i služi kao kompaktan pokazatelj kvaliteta rangiranja modela. Modeli na redukovanom skupu pokazuju karakteristično različite profile koji odražavaju njihovu tendenciju ka visokom recallu.




5.4. Crossvalidation

Kako bi se osigurala robustnost evaluacije i minimizovao uticaj konkretne podele podataka, primenjena je Stratified K-Fold crossvalidation sa 5 foldova. Stratifikacija osigurava da svaki fold zadrži isti udeo bankrota kao originalni skup. Crossvalidation je primenjena na metriku odziv za klasu bankrota, primarnu metriku ovog istraživanja. Rezultati su vizuelizovani bar grafikom sa standardnom devijacijom kao error barovima, što omogućava vizuelnu procenu stabilnosti performansi pojedinih modela.

5.5. Feature Importance - Random Forest

Random Forest kao ansambl stabala ima inherentnu sposobnost merenja važnosti atributa kroz Gini impurity redukciju. Top 20 atributa rangirano je po prosečnoj važnosti kroz sva stabla u ansamblu i prikazano horizontalnim bar grafikom. Ovaj grafik dopunjuje nalaze SelectKBest analize i pruža pogled specifičnog modela na to koji finansijski indikatori nose najviše prediktivne snage unutar ansambla.



6. Analiza rezultata

Svaki od pet algoritama treniran je i evaluiran u dva scenarija: na punom skupu od 95 atributa, i na redukovanom skupu od 10 atributa selektovanih ANOVA F-testom. Ovakav dizajn eksperimenta omogućava direktno poređenje uticaja selekcije atributa na performanse, a rezultati otkrivaju važne i ponekad kontraintuitivne zaključke.

6.1. Tabela tačnosti (Accuracy)

Algoritam	Svi atributi (95)	Redukovani atributi (10)
Logistic Regression	0.8866	0.8719
Decision Tree	0.9394	0.8998
Random Forest	0.9624	0.9218
KNN	0.8866	0.8763
SVM	0.9037	0.8500


6.2. Tabela Recall-a za klasu Bankrot


Algoritam	Svi atributi (95)	Redukovani atributi (10)
Logistic Regression	~0.65	0.85
Decision Tree	~0.55	~0.60
Random Forest	0.55	~0.58
KNN	~0.45	~0.50
SVM	~0.60	~0.80

6.2. Paradoks visoke tačnosti — slučaj Random Forest

Na prvi pogled, Random Forest sa tačnošću od 96.24% deluje kao ubedljiv pobednik. Međutim, ovo je klasičan primer "paradoksa tačnosti" koji se javlja u domenima s nebalansiranim podacima. Detaljnija analiza konfuzione matrice otkriva da model ima odziv svega 0.55 za klasu bankrota, što znači da propušta skoro 45% kompanija koje će zapravo bankrotirati, svrstava ih kao stabilne subjekte i time pruža lažan osećaj sigurnosti.

Zamislimo konkretan scenario: menadžer koji koristi ovaj model za nadzor 1.000 kompanija, od kojih 40 (4%) pretpostavlja bankrot. Random Forest će ispravno identifikovati 22 od njih, ali će 18 propustiti, a to su upravo oni slučajevi koji dovode do direktnih finansijskih gubitaka. Nasuprot tome, model sa odzivom 0.85 detektuje 34 od 40 rizičnih kompanija, i to uprkos nižoj ukupnoj tačnosti. Sa čisto poslovne perspektive, ovaj model je daleko vredniji.





6.3. Efekat redukcije atributa na odziv

Jedan od najzanimljivijih nalaza ovog istraživanja jeste da su modeli trenirani na redukovanom skupu od 10 atributa generalno pokazali bolji odziv za detekciju bankrota, uprkos nižoj ukupnoj tačnosti. Ova naizgled kontrainuitivna pojava ima solidno statističko objašnjenje.

Kada model ima na raspolaganju 95 atributa, od kojih je mnogo korelisano ili irelevantno, postoji visoka verovatnoća da se fokusira na statistički šum u trening skupu. Svođeci skup na 10 najinformativnijih atributa, model je prisiljen da se osloni isključivo na signale koji su najjače asocirani sa bankrotom, pre svega ROA i Debt Ratio, što rezultira generalizabilnijim obrascima koji bolje funkcionišu na neviđenim primerima.

Logistička regresija na redukovanom skupu postiže odziv od **0.85**, što znači da bi uspešno detektovala 85 od 100 kompanija koje zapravo bankrotiraju. Ovaj rezultat je posebno impresivan s obzirom na linearnu prirodu modela, i direktno potvrđuje tezu da pažljivo odabrana mala kolekcija finansijskih indikatora nosi više prediktivne snage od stotine sirovih koeficijenata.

6.4. Trade-off: Preciznost vs. Odziv

Kao što je i teorijski očekivano, modeli s visokim odzivom plaćaju cenu u obliku niže preciznosti. Logistička regresija i SVM na redukovanom skupu imaju preciznost oko 0.15–0.18 za klasu bankrota, što znači da od svih kompanija koje model označi kao rizične, samo 15–18% zaista bankrotira. Preostalih 82–85% su lažni alarmi.

Da li je ovo prihvatljivo? Odgovor zavisi od konteksta primene. U scenariju kreditnog rejting sistema ili sistema ranog upozorenja regulatora, visok broj lažnih alarma je ekonomski opravdan: trošak dodatne analize potencijalno lažne uzbune (manuelni pregled finansija jedne kompanije) neuporedivo je manji od direktnog gubitka koji nastaje usled propuštenog bankrota. Princip je sličan onome u medicinskoj dijagnostici, test na teško oboljenje može imati visoku stopu lažno pozitivnih, ali niko ne bi promenio algoritam samo da bi smanjio broj nepotrebnih pregleda, ako bi to značilo propuštanje pravih slučajeva.

Pravi kompromis, optimalna tačka na krivoj precision-recall, zavisi od poslovnih prioriteta i treba je odrediti u konsultaciji sa domenskim ekspertima. Za institucije čiji je primarni cilj zaštita od gubitaka, visok odziv je nepregovarajuća osnova.

7. Zaključak

7.1. Superiornost selekcije atributa i interpretabilnost

Rezultati su nedvosmisleno potvrdili tezu da "više podataka" ne podrazumeva nužno i "bolji model". Fokusiranjem na svega 10 ključnih finansijskih pokazatelja, dobili smo modele koji su otporniji na statistički šum i generalizabilniji na neviđenim primerima. Ova redukcija atributa ima kritičnu vrednost ne samo u tehničkom, već i u poslovnom smislu, kreditni analitičari i menadžeri finansijskog rizika mogu interpretirati nalaze i razumeti koje operativne dimenzije su najkritičnije, umesto da se suočavaju sa neprozirnim prostorom od 95 apstraktnih koeficijenata. Jasno je da se finansijsko zdravlje kompanije u prvom redu ogleda u njenoj sposobnosti da generiše profit iz imovine (ROA) i kontroliše nivo zaduženosti (Debt Ratio).

7.2. Strategija upravljanja greškama: Recall vs. Precision

Jedan od najvažnijih zaključaka ovog rada je da se uspeh modela za predikciju bankrota mora meriti kroz prizmu poslovnog rizika, a ne samo proste statističke tačnosti. Analiza je pokazala da modeli s nešto nižom ukupnom tačnošću, poput logističke regresije i SVM-a na redukovanom skupu, zapravo pružaju bolju zaštitu od finansijskog kolapsa, jer uspevaju da detektuju značajno veći udeo stvarnih bankrota. Svaki sistem ranog upozorenja koji se implementira u bankama, osiguravajućim kompanijama ili investicionim fondovima mora eksplicitno definisati prihvatljivi pragove i prioritete između ove dve metrike, u skladu sa regulatornim okvirom i poslovnom strategijom institucije.

7.3. Balansiranje podataka kao ključ uspeha

Istraživanje je potvrdilo da je primena tehnika poput SMOTE-a apsolutno nezaobilazna u finansijskim analizama. Bez veštačkog generisanja primera manjinske klase, algoritmi bi, usled optimizacije ukupne greške, težili da svaku firmu klasifikuju kao stabilnu, i pritom postigli visoku tačnost bez ikakve stvarne prediktivne vrednosti. Pravilno balansiranje omogućava modelu da nauči suptilne, ali kritične obrasce ponašanja firme koje klize ka nelikvidnosti. Ovo je ključno za svaku instituciju koja želi da automatizuje sistem ranog upozorenja.

7.4. AI kao katalizator finansijske stabilnosti

Implementacija ovakvih modela u bankarskom sektoru ili na finansijskim tržištima može transformisati način na koji se donose odluke. Umesto manuelne, retrospektivne analize bilansa stanja, mašinsko učenje omogućava proaktivni nadzor u realnom vremenu. Sistem može automatski signalizirati kompanije čiji se indikatori pogoršavaju kroz vreme, omogućavajući pravovremeno restrukturiranje, ograničavanje daljeg zaduživanja ili opozivu kreditnih linija pre nego što kompanija postane nesolventna. Na makroekonomskom nivou, ovakvi sistemi direktno doprinose smanjenju sistemskog rizika i finansijskoj stabilnosti celokupnog tržišta.

Ovakav pristup je posebno vredan u kontekstu ESG (Environmental, Social, Governance) investiranja i regulatorne usklađenosti: algoritmi koji rano detektuju finansijsku nestabilnost mogu biti integrisani u šire platforme za upravljanje rizicima, pružajući regulatorima alat za makroprudencijalni nadzor koji prevazilazi mogućnosti tradicionalnih pristupa.

7.5. Ograničenja i horizonti budućih istraživanja

Uprkos obećavajućim rezultatima, moramo biti svesni ograničenja ovog istraživanja. Podaci su statični godišnji preseki stanja, dok je bankrot dinamičan proces koji se odvija kroz vreme, kompanija retko bankrotira iznenada; najčešće prolazi kroz period postepenog pogoršanja. Modeli koji smo razvili ne mogu da uhvate ove trendove.

Buduća istraživanja trebalo bi da se fokusiraju na temporalne modele poput LSTM (Long Short-Term Memory) ili GRU arhitektura koje bi pratile evoluciju finansijskih indikatora kroz višegodišnje serije. Integracija faktora kao na primer inflacije, kamatnih stopa centralnih banaka, kreditnih premija i mere ekonomske neizvesnosti, nesumnjivo bi poboljšala tačnost predviđanja u turbulentnim ekonomskim ciklusima, kada se sistemski rizik povećava i bankroti nisu samo izolovan poslovni neuspeh već simptom širih ekonomskih poremećaja.

Pored toga, vredelo bi istražiti i primenu AI metoda (Explainable AI — XAI), kao što su SHAP vrednosti ili LIME, kako bi se za svaku klasifikovanu kompaniju generisalo objašnjenje koje finansijski stručnjaci mogu da razumeju i komuniciraju dalje. Transparentnost i interpretabilnost modela postaju sve važniji regulatorni i etički zahtev u finansijskoj industriji.

Na kraju, možemo zaključiti da mašinsko učenje predstavlja nezaobilazan alat u arsenalu modernog ekonomiste i finansijskog stručnjaka. Pravilnim izborom modela, metrika evaluacije i fokusiranjem na relevantne attribute, moguće je transformisati sirove finansijske podatke u stratešku prednost, alat koji čuva kapital, smanjuje sistemski rizik i na kraju, doprinosi zdravijem i stabilnijem finansijskom ekosistemu.