

Taiwanese Bankruptcy Prediction

1. Uvod i opis zadatka

Cilj ovog rada je analiza skupa podataka "Taiwanese Bankruptcy Prediction" i kreiranje prediktivnih modela koji mogu klasifikovati da li će kompanija bankrotirati ili ne na osnovu finansijskih pokazatelja. Problem je definisan kao binarna klasifikacija.

2. Opis podataka


Podaci su preuzeti iz UCI Machine Learning repozitorijuma.

- Izvor:** Ekonomске regulative Tajvanske berze.
- Broj instanci:** 6819.
- Broj atributa:** 95 finansijskih atributa + 1 ciljna promenljiva.
- Ciljna promenljiva:** Bankrupt? (1 = Bankrot, 0 = Nije bankrot).
- Struktura:** Podaci su izrazito neuravnoteženi (nebalansirani), gde je broj bankrotiranih firmi znatno manji od stabilnih, što predstavlja glavni izazov u modelovanju.

3. Metodologija i obrada podataka (Preprocesiranje)

Za obradu podataka korišćen je programski jezik Python sa bibliotekama pandas, sklearn i imblearn. Sprovedeni su sledeći koraci:

- Čišćenje podataka:** Provereno je postojanje nedostajućih vrednosti.
- Vizuelizacija:** Izvršena je redukcija dimenzionalnosti na 2D prostor koristeći PCA (Principal Component Analysis) radi vizuelnog uvida u separabilnost klasa.



3. **Skaliranje:** Svi numerički atributi su normalizovani koristeći StandardScaler (srednja vrednost 0, devijacija 1), što je neophodno za algoritme poput SVM i KNN.
4. **Balansiranje klasa:** S obzirom na mali broj primera bankrota, na trening skupu je primenjena **SMOTE** (Synthetic Minority Over-sampling Technique) metoda kako bi se veštački generisali primeri manjinske klase i izbalansirao odnos.
5. **Redukcija atributa:** Kreiran je poseban podskup podataka gde je metodom SelectKBest (ANOVA F-value) izdvojeno 10 najuticajnijih finansijskih pokazatelja.

4. Korišćeni algoritmi

U skladu sa zahtevima, primenjeno je 5 različitih algoritama mašinskog učenja:

1. **Logistic Regression:** Kao osnovni linearни model.
2. **Decision Tree:** Zbog interpretabilnosti pravila odlučivanja.
3. **Random Forest:** Kao ansambl metoda za veću stabilnost.
4. **K-Nearest Neighbors (KNN):** Algoritam baziran na instancama.
5. **Support Vector Machine (SVM):** Za pronalaženje optimalne hiperravnji.


5. Analiza rezultata

Modeli su trenirani u dva scenarija:

1. Sa svim atributima (95 atributa).
2. Sa redukovanim skupom (10 atributa).

Tabela rezultata (Tačnost / Accuracy):

| Algoritam | Svi atributi | Redukovani atributi |
|---------------------|--------------|---------------------|
| Logistic Regression | 0.8866 | 0.8719 |
| Decision Tree | 0.9394 | 0.8998 |
| Random Forest | 0.9624 | 0.9218 |
| KNN | 0.8866 | 0.8763 |
| SVM | 0.9037 | 0.8500 |



Diskusija:

Problem nebalansiranih podataka: Iako **Random Forest** na punom skupu podataka ima najveću ukupnu tačnost (96.24%), njegov odziv (Recall) za detekciju bankrota je nizak (0.55). To znači da model propušta skoro polovinu firmi koje će zapravo bankrotirati, klasificujući ih kao stabilne.

- **Efekat redukcije atributa:** Zanimljivo je da su modeli na redukovanim skupima (samo 10 atributa) pokazali **bolju sposobnost detekcije bankrota** (veći Recall), iako je ukupna tačnost blago opala.
- Na primer, **Logistic Regression** na redukovanim skupima ima Recall od **0.85**. To znači da ovaj model uspešno detektuje 85% svih bankrota, što je u praksi mnogo korisnije od visoke tačnosti koja dolazi od pogađanja većinske klase.
- **Trade-off (Preciznost vs. Odziv):** Primećujemo da modeli sa visokim Recall-om (LogReg, SVM na redukovanim skupima) imaju nisku preciznost (oko 0.15 - 0.18). To znači da modeli često dižu "lažnu uzbunu" (predviđaju bankrot tamo gde ga nema), ali je to prihvatljiva cena kako bi se detektovala većina stvarnih rizičnih slučajeva.

6. Zaključak

Cilj ovog rada bio je kreiranje modela za predikciju bankrota tajvanskih kompanija. Kroz proces obrade podataka, balansiranja klasa (SMOTE) i selekcije atributa, došli smo do sledećih zaključaka:

1. **Finansijski indikatori:** Bankrot se može uspešno predvideti praćenjem malog broja ključnih parametara, prvenstveno **ROA (povrat na imovinu)** i **Debt ratio (zaduženost)**. Korišćenje svih 96 atributa nije neophodno i može dovesti do preprilagođavanja (overfitting).
2. **Izbor modela:** Za ovaj specifičan problem, gde je "skuplje" propustiti bankrot nego lažno optužiti stabilnu firmu, **Logistic Regression sa redukovanim skupom atributa** se pokazala kao najkorisniji model. Iako nema najveću ukupnu tačnost, ima najveći **Recall (85%)**, što je ključno za upravljanje rizikom.
3. **Upravljanje podacima:** Balansiranje podataka je bio kritičan korak. Bez primene tehnika poput SMOTE-a, modeli bi težili da sve klasifikuju kao "stabilno" zbog malog broja primera bankrota u originalnom skupu.

Možemo zaključiti da je mašinsko učenje moćan alat za finansijsku analizu, ali da se uspeh modela ne sme meriti samo prostom tačnošću (Accuracy), već se mora uzeti u obzir specifičnost problema (Recall vs. Precision).